EJERCICIO 3

Resúmenes

Artículo 1. Datos sísmicos

1. Problema e importancia. Los sismos son impredecibles y de alto impacto. México se ubica en el Cinturón de Fuego del Pacífico y sobre cinco placas tectónicas, por lo que cerca del 70 % del territorio está expuesto a riesgo sísmico, incluidas zonas densamente pobladas como el Valle de México y Guadalajara. El Servicio Sismológico Nacional (SSN) publica datos detallados, pero su carácter técnico y su formato dificultan que el público general los use. El trabajo busca volverlos accesibles para la gestión gubernamental, la educación y concientización, y la investigación científica.

2. Datos y preparación. Del SSN se descarga un CSV con más de 300 000 sismos registrados desde 1900; del INEGI, dos CSV: el Censo de Población y Vivienda 2020 y los Censos Económicos (2019 en el texto; la bibliografía cita la edición 2024). Aunque las bases están bien construidas, contienen registros inválidos. Un programa en Python lee los archivos, detecta campos vacíos, coordenadas inconsistentes y formatos incompatibles, elimina los registros inválidos y genera código SQL con los datos validados, que se carga en PostgreSQL.

3. Modelado de la información. Los datos de sismos, población y economía se organizan en PostgreSQL con estructura de almacén de datos (data warehouse). Por tratarse de un artículo de divulgación, no describe tablas de hechos ni dimensiones de forma explícita. De lo expuesto se infiere que el evento sísmico (magnitud, profundidad, coordenadas, periodo) es el elemento central y que se relaciona con población y producción económica a través de la ubicación (estado y localidad). Servicios en PHP 8 sobre Apache consultan el almacén y una interfaz web (HTML5, Bootstrap, JavaScript, OpenStreetMap) presenta los resultados.

4. Preguntas que responde. Mapas interactivos filtrados por magnitud (por ejemplo, sismos de 2 grados o más, con localidades de 50 000 habitantes o más resaltadas) para ver qué poblaciones están cerca de los epicentros; reportes estadísticos por estado, año o todo el país (como los sismos de 2017 en Jalisco); mapas de calor que muestran el alcance de un sismo y las localidades afectadas; y reportes personalizados con filtros de periodo, magnitud, localidad, profundidad, número de habitantes o producción económica. También permite comparar aumentos o disminuciones de actividad sísmica a lo largo de 125 años.

5. Limitaciones y trabajo futuro. Los autores señalan que los sismos no pueden pronosticarse con certeza y que instalar el sistema puede ser complicado para quien domina poco las herramientas; lo abordan con Docker Compose (dos contenedores: base de datos y servidor web) y un repositorio público en GitHub. El texto no presenta una evaluación formal. Como trabajo futuro proponen visualizaciones en 3D, más fuentes oficiales de datos e integración con plataformas de alerta temprana.

Artículo 2. Consumo de agua en la Ciudad de México

1. Problema e importancia. La Ciudad de México enfrenta una crisis hídrica por sobreexplotación de acuíferos, fugas en la red y crecimiento poblacional. El SACMEX publica datos abiertos de consumo, pero en formatos poco accesibles y sin herramientas de consulta, lo que limita las decisiones basadas en evidencia. El trabajo los convierte en un repositorio consultable que ciudadanos, funcionarios, investigadores y periodistas pueden filtrar y visualizar por alcaldía y colonia.

2. Datos y preparación. La fuente es el CSV «Consumo Agua (1er Semestre 2019)» del portal de datos abiertos de la CDMX (71 102 registros; tres bimestres con una fecha de lectura cada uno; una fila por manzana y periodo de facturación), sin esquema ni versionado. Se añadió una serie climática diaria de Open-Meteo. El ETL tiene cuatro fases: extracción, validación y limpieza, carga a tablas temporales con poblado de dimensiones, y poblado de hechos. Se descartaron 216 registros (0.30 %) por etiquetas territoriales «NA», y quedaron 70 886. Se recuperaron coordenadas presentes en la fuente que el esquema de carga original había omitido.

3. Modelado de la información. Esquema en estrella en PostgreSQL con dos tablas de hechos, fact_consumo_agua y fact_clima, y tres dimensiones conformadas: dim_tiempo (fecha, año, bimestre), dim_ubicacion (alcaldía, colonia, latitud, longitud; 1 553 pares) y dim_indice_des (nivel de desarrollo: alto, medio, bajo, popular). La medida principal es el consumo por manzana y periodo; la dimensión de tiempo compartida permite consultar consumo y clima juntos. Mediante un mapeo declarativo R2RML, el modelo se republica como grafo de conocimiento RDF Data Cube (unos 7.6×10^5 tripletas), validado con restricciones de integridad del vocabulario.

4. Preguntas que responde. Cuánto se consume por año, bimestre, alcaldía y colonia (Cuauhtémoc y Miguel Hidalgo encabezan el total); qué colonias cercanas (a menos de 1.5 km) a una zona consumen más, mediante consultas SPARQL sobre el grafo; qué unidades conviene revisar primero, con un puntaje de atipicidad que compara cada colonia con su alcaldía; cómo se relaciona el consumo con el índice de desarrollo; y qué proporción es no doméstica (32.5 % en Cuauhtémoc frente a 20.3 % en Gustavo A. Madero). Los autores advierten que el total no es un indicador per cápita.

5. Limitaciones y trabajo futuro. Reconocen que la fuente cubre solo tres bimestres de 2019, por lo que no se puede estimar estacionalidad ni correlación climática; que el módulo de atipicidad se evaluó con anomalías sintéticas y no detecta fugas reales (ROC-AUC de 0.966 frente a 0.971 de Isolation Forest); que las colonias son centroides y no polígonos, así que la «adyacencia» es proximidad; y que la asociación con el índice de desarrollo es solo descriptiva. Proponen un almacén de tripletas con punto de acceso SPARQL público, polígonos oficiales, alinear identificadores con fuentes externas, reevaluar con datos etiquetados de fugas y extender el método a movilidad, calidad del aire y riesgo sísmico.

Artículo 3. Obra pública municipal

1. Problema e importancia. La transparencia en la obra pública municipal es un reto persistente: muchos municipios trabajan con archivos dispersos, hojas de cálculo o sistemas transaccionales aislados, lo que impide el análisis histórico, la detección temprana de retrasos y una participación ciudadana informada. El artículo diseña un prototipo para Temascaltepec, Estado de México (64 844 habitantes, 55 comunidades), y pregunta si un almacén de datos dimensional sobre servicios gestionados de bajo costo puede dar trazabilidad auditable sin plataformas empresariales.

2. Datos y preparación. Los datos no son reales: por restricciones de privacidad, todo es sintético. Un generador con semilla produjo 1 247 obras, un presupuesto de 127.4 millones de pesos, 29 928 filas mensuales, 8 934 eventos de auditoría, 3 421 evidencias fotográficas, 2 156 propuestas y 8 723 votos; la detección usó una simulación aparte. La información se captura en formularios web (texto, coordenadas, montos, fotos y PDF); la evidencia binaria va a Cloudflare R2 y el almacén se alimenta con disparadores de base de datos, no con un ETL externo. Las coordenadas provienen de OpenStreetMap, con un desplazamiento de hasta 150 m entre obras.

3. Modelado de la información. Esquema en estrella en PostgreSQL con diez dimensiones y dos tablas de hechos. fact_audit_events registra un evento de auditoría por fila (17 tipos, particionada por año); fact_work_monthly es una fotografía periódica por obra y mes (presupuesto, costo acumulado, avance físico, retraso). Cinco dimensiones son de tipo 2, con historial de versiones (obra, región, empresa, personal, presupuesto); tres, de tipo 1 (fuente, ciudadano, propuesta); y dos, de tipo 0 (tiempo, tipo de evento). Seis vistas analíticas se sirven por una API REST, y el «grafo» del mapa está implícito en las llaves foráneas.

4. Preguntas que responde. Qué obras están retrasadas y cuántos días; qué alertas de auditoría existen (monto alto, obra cancelada, cambio de presupuesto); cuál era el estado de una obra o qué presupuesto estaba vigente cuando se autorizó un pago, y a qué contratista correspondía el avance; cómo se distribuyen votos y propuestas por región; cuánto se ha ejecutado por fuente de financiamiento; y qué obras presentan anomalías (costo atípico, retraso mayor a 120 días o avance físico menor a 30 % con avance financiero mayor a 80 %). El visor geoespacial muestra el estado de cada obra por color.

5. Limitaciones y trabajo futuro. Todo resultado proviene de datos sintéticos y nada se validó con registros municipales. La regla de detección alcanza 0.46 de precisión y 0.35 de recall, y Isolation Forest la supera como puntuación (ROC-AUC 0.65 frente a 0.63); falla sobre todo con sobreprecio y pagos adelantados. Tampoco hay despliegue dinámico alojado, la capa de objetos aún no se consulta analíticamente, el control de acceso es ligero y la votación es simple. Como trabajo futuro proponen evolucionar hacia un lakehouse con un formato de tabla abierto (Iceberg o Parquet), clasificar el avance con visión por computadora, publicar el esquema como vocabulario OWL y compatible con OC4IDS, votación cuadrática, modelos de series de tiempo, recalibrar el criterio de costo y validar en más municipios.